# Universidad Tecnológica Nacional
# Facultad Regional Rosario

Especialidad: Ing. en Sistemas de Información.

Asignatura: Algoritmos Genéticos

Comisión: 3EK03

Ciclo lectivo: 2025

Fecha: 12/06/2025

## TRABAJO PRÁCTICO N°1:

## Maximización de una función objetivo


| Alumno | Correo | Legajo |
|---|---|---|
| Mondino, Juan Cruz | juancm.2000@hotmail.com | 51922 |
| Giampietro, Gustavo | gustgiam2001@gmail.com | 50671 |
| Mateo, Alexis | alexisjoelmateo@gmail.com | 51191 |

# Contenido

## Enunciado

Hacer un programa que utilice un Algoritmo Genético Canónico para buscar un máximo de la función:

$$f(x) = \left(\frac{x}{coef}\right)^2$$

en el dominio [0 , $2^{30}$-1], donde:

$$coef = 2^{30} - 1$$

Teniendo en cuenta los siguientes datos:

- Probabilidad de Crossover = 0,75.
- Probabilidad de Mutación = 0,05.
- Población Inicial: 10 individuos.
- Ciclos del programa: 20.
- Métodos de selección: Ruleta, Torneo y Elitismo.
- Método de Crossover: 1 Punto.
- Método de Mutación: invertida.
- Cantidad de individuos seleccionados por elitismo: 2.

El programa debe mostrar los siguientes datos para los diferentes métodos de selección:

1. El cromosoma correspondiente al valor máximo, el valor máximo, mínimo y promedio obtenido de cada población.
2. La impresión de las tablas de mínimos, promedios y máximos para 20, 100 y 200 corridas (para elitismo solamente los valores de 100 iteraciones del algoritmo).
3. Las gráficas de los valores Máximos, Mínimos y Promedios de la función objetivo por cada generación luego de correr el algoritmo genético 20, 100 y 200 iteraciones (para elitismo solamente las gráficas de 100 iteraciones del algoritmo).
4. Realizar comparaciones de las salidas corriendo el mismo programa en distintos ciclos de corridas y además realizar todos los cambios que considere oportunos en los parámetros de entrada de manera de enriquecer sus conclusiones.

## Metodología de desarrollo

El programa consiste en ejecutarlo con la siguiente línea:

*Python TP1_AG_G2.py -c N -s M -e B*

Donde:

- N es un número entero que representa la cantidad de ciclos, o generaciones, para las que uno quiere que se ejecute el programa.
- M es uno de entre dos valores, la letra “r” o la “t”. De esta forma se representa si se quiere efectuar el método de ruleta o el método de torneo respectivamente.
- Por último, B puede ser un valor entre 1 o 0, siendo 1 el que indique que se usará elitismo y siendo 0 para el caso contrario.

Con esta información, inicializa las variables del algoritmo, como la probabilidad de crossover, la probabilidad de mutación, la cantidad de individuos, la cantidad de genes por individuo, el coeficiente de normalización (*coef*) y, en caso de usarse torneo, cuántos competidores participan por ronda.

Luego se genera la población inicial: una lista de cromosomas binarios aleatorios. Cada cromosoma es una lista de 0s y 1s. A esta población se le calcula el fitness de cada cromosoma evaluando su valor decimal con la función objetivo enunciada anteriormente, y finalmente calcula su fitness relativo dentro de la población, es decir, su proporción respecto de la suma total de objetivos. Paralelamente, se calcula el máximo, mínimo, promedio y mejor individuo.

A partir de aquí, se inicia el ciclo evolutivo. El programa decide si usará elitismo o no. En caso afirmativo, se seleccionan los mejores individuos según fitness y se los aparta para preservarlos (los llamaremos elitistas). El resto de la nueva generación se obtiene por uno de los dos métodos de selección: ruleta, que asigna probabilidad proporcional al fitness, o torneo, donde se eligen aleatoriamente grupos de competidores y se selecciona el mejor de cada grupo.

Una vez seleccionados los individuos para la siguiente generación (sin contar a los elitistas), el algoritmo procede a evaluar la probabilidad de crossover. Si se termina dando, toma pares de individuos y aplica el operador de cruce en un punto, generando dos hijos. Luego, con otra probabilidad, analiza si debe aplicar una mutación a cada uno de los hijos, alterando aleatoriamente un gen de su cromosoma. Cuando se termina este proceso, si hay elitismo, los mejores individuos originales se reincorporan a la población sin modificaciones.

Con la nueva población formada, se vuelve a calcular el fitness y las estadísticas. Los valores máximos, mínimos, promedios y el mejor cromosoma de esa generación se almacenan para su posterior análisis. Este proceso se repite durante la cantidad de ciclos especificada por el usuario.

Una vez finalizados todos los ciclos, se generan los gráficos representando la evolución del valor máximo, mínimo y promedio de fitness a lo largo de las generaciones. Por último, se crea un archivo Excel, que contiene los datos obtenidos ciclo a ciclo, incluyendo el mejor cromosoma en formato binario y decimal.

El objetivo del programa es simular un algoritmo genético que permita analizar y comparar el comportamiento evolutivo de distintas estrategias de selección (ruleta y torneo), con y sin elitismo, observando cómo afectan a la convergencia de la población hacia la solución

óptima (el mayor número posible dentro del dominio [0; $2^{30}$-1] que sea un máximo de la función objetivo), a través de la observación de las estadísticas en los gráficos.

## Forma de trabajo abordada en equipo

Para realizar las corridas de la simulación nuestro grupo eligió programar en Python el algoritmo, para ello fue utilizado el editor de código fuente Visual Studio Code.

Como cada uno de nosotros trabajó desde su propia computadora fueron utilizadas herramientas como Google Drive, en donde fueron creadas carpetas y documentos compartidos para que cada uno pueda editar libremente, y GitHub, para poder codear sin necesidad de ir pasando el documento entre nosotros, además de aprovechar la seguridad que aporta este sistema de control de versiones online.

## Herramientas de programación

Como ya fue mencionado se utilizó Python para programar los algoritmos. Pero dentro de este lenguaje fueron utilizadas diferentes librerías con el fin de implementar las siguientes funciones:

- OS: Se utiliza para realizar operaciones sobre el sistema de archivos, como verificar si existe un archivo con un nombre determinado y eliminarlo en caso de ser necesario. También permite limpiar la pantalla del terminal, dependiendo del sistema operativo (Windows, Linux, etc.).
- RANDOM: Su utilización surge por la necesidad de tener un generador de números aleatorios confiable. Además, uno puede limitar el dominio de posibles números aleatorios o especificar si es entero o real.
- SYS: Se emplea para manejar argumentos desde la línea de comandos, lo que permite ejecutar el programa con distintos parámetros (por ejemplo, cantidad de ciclos, tipo de selección, uso o no de elitismo) sin modificar el código fuente.
- MATPLOTLIB.PYPLOT: Esta librería permite generar gráficos durante o después de la ejecución del programa. Se usa para visualizar la evolución de las métricas del algoritmo (como el fitness máximo, mínimo y promedio), lo cual facilita el análisis y comprensión de los resultados.
- PANDAS: Es una herramienta poderosa para la manipulación de datos en forma de tablas. Se utiliza para construir DataFrames y exportarlos a archivos Excel (.xlsx), lo que permite guardar los resultados del algoritmo en un formato claro y accesible.
- OPENPYXL: Es el motor que PANDAS usa por defecto para escribir archivos Excel. Es necesario tenerla instalada para que la función to_excel() de PANDAS funcione correctamente con archivos .xlsx.

## Código

En este apartado se explicará parte por parte el código Python utilizado para correr las simulaciones:

En la parte superior del código se especifican las librerías que se utilizarán y deben ser instaladas para correr el programa.

```
import random
import os
import sys
import matplotlib.pyplot as plt
import pandas as pd
# Utiliza openpyxl tambien
```

Luego, se definieron dos funciones. La primera es utilizada para obtener un número aleatorio entre 0 y 1 de una manera más sencilla.

```
def aleatorio():
    return random.randint(0, 1)

def completoCromosoma(cantidad):
  cromosoma = [aleatorio() for _ in range(cantidad)]
  return cromosoma
```

La segunda, se la llama cuando se requiere obtener un cromosoma completo, uno solamente debe pasarle la cantidad de genes que debe tener dicho cromosoma y la función creará el cromosoma con la longitud especificada completo por ceros y unos aleatoriamente. Aquí se busca obtener una población de una cantidad de individuos o cromosomas especificada, ésta es la función que llama a la explicada anteriormente para que complete los genes de cada cromosoma.

```
def generarPoblacion(cantidadCromosomas, cantidadGenes):
    poblacion = []
    for i in range(cantidadCromosomas):
        cromosoma = completoCromosoma(cantidadGenes)
        poblacion.append(cromosoma)
    return poblacion
```

binarioADecimal es una función que utilizamos para convertir a un cromosoma, que se puede tomar como un número binario, a su correspondiente número decimal.

```
def binarioADecimal(cromosoma):
    decimal = 0
    exponente=0
    for i in range(len(cromosoma)-1,-1,-1):
        if cromosoma[i] == 1:
            decimal = decimal + pow(2,exponente)
        exponente += 1
    return decimal

def funcionObjetivo(x):
    return (x / coef) ** 2
```

funcionObjetivo se llama para evaluar qué tan buena es una solución candidata. Toma un valor (o conjunto de valores) como parámetro y devuelve una medida numérica que representa su calidad o desempeño según el problema que se busca resolver.

```
def funcionObjetivo(x):
    coef = (2 ** 30) - 1
    return (x / coef) ** 2
```

En la función crossover, se reciben dos parámetros que son los padres por combinar para obtener dos nuevos individuos de la población. Entonces, se elige un punto aleatorio dentro de cada individuo para “cortarlo” y unirlo a la otra parte del segundo individuo, obteniendo así los dos nuevos cromosomas de la nueva generación.

```
def crossover1Punto(padre, madre):
    puntoCorte = random.randint(1,len(padre)-1)
    h1 = padre[:puntoCorte] + madre[puntoCorte:]
    h2 = madre[:puntoCorte] + padre[puntoCorte:]
    return h1, h2
```

Esta es la función encargada de devolver las métricas de rendimiento de cada generación, sirve para monitorear el progreso.

```
def calculadorEstadisticos(poblacion):
    objetivos = [funcionObjetivo(binarioADecimal(ind)) for ind in poblacion]
    max_objetivos = max(objetivos)
    min_objetivos = min(objetivos)
    mejor_cromosoma = poblacion[objetivos.index(max_objetivos)]
    avg_objetivos = round((sum(objetivos)/len(objetivos)),4)
    return [max_objetivos,min_objetivos, avg_objetivos, mejor_cromosoma]
```

La medida devuelta por la funcionObjetivo es luego utilizada acá, en la función calculadorFitness, donde se calcula el fitness relativo de cada individuo dividiendo su valor objetivo por la suma total de todos los objetivos. Esto normaliza los valores, de forma que el fitness de cada individuo representa su proporción de aptitud respecto al total, lo cual es clave para el mecanismo de selección.

```
def calculadorFitness(poblacion):
    fitness = []
    objetivos = []
    sumatoria = 0
    for individuo in poblacion:
        decimal = binarioADecimal(individuo)
        obj = funcionObjetivo(decimal)
        objetivos.append(obj)
        sumatoria += obj
    if sumatoria == 0:
        print ('La suma de los valores es igual a cero.', poblacion)
        exit()
    for i in range (len(poblacion)):
        peso = objetivos[i]/sumatoria
        fitness.append(round(peso,5))
    return fitness
```

La función mutacionInvertida se utiliza para aplicar variaciones aleatorias a los individuos de la población. Su objetivo es mantener la evolución genética como es en la realidad (al menos lo más cercano posible) modificando ligeramente los cromosomas dependiendo de una probabilidad establecida.

Ésta implementa un tipo de mutación por inversión, donde se selecciona un segmento aleatorio del cromosoma y se invierte el orden de los genes dentro de ese segmento.

```
#Mutacion
def mutacionInvertida(hijo):
    cantGenes = len(hijo)
    if cantGenes < 2:
        return hijo
    posInicial = random.randint(0, cantGenes - 2)
    posFinal = random.randint(posInicial + 1, cantGenes - 1)
    segmento = hijo[posInicial:posFinal + 1]
    hijo[posInicial:posFinal + 1] = segmento[::-1]
    return hijo
```

La función seleccionRuleta Implementa el método de selección por ruleta, donde cada individuo tiene una probabilidad de ser elegido proporcional a su valor de fitness. Se usa para formar la nueva generación favoreciendo a los más aptos, pero manteniendo algo de aleatoriedad.
Con los dos for es creado el arregloRuleta con cantidades repetidas proporcionales al fitness de cada individuo, se multiplica por 100000 para volver todos los números reales que puede haber a enteros y diferenciar mejor entre los individuos con menor fitness, y finalmente se realiza una selección aleatoria sobre el arreglo ruleta.

```
# Ruleta
def seleccionRuleta(poblacion, fitnessValores, cantidad):
    arregloRuleta = []
    seleccionados = []
    for i in range(len(fitnessValores)):
        fitnessValores[i] = fitnessValores[i]*100000
        fitnessValores[i] = int(fitnessValores[i])
        for j in range(fitnessValores[i]):
            arregloRuleta.append(poblacion[i])
    for i in range (cantidad):
            nro = random.randint(0,99999)
            seleccionados.append(arregloRuleta[nro])
    return seleccionados
```

Luego se realiza la selección por torneo utilizando seleccionTorneo, donde se eligen varios competidores al azar y gana el que tiene mayor fitness. Se repite hasta completar la cantidad de individuos requeridos. Es un método de selección que introduce competencia directa entre cromosomas.

```
# Torneo
def seleccionTorneo(poblacion, fitnessValores, cantidadIndividuos, cantidadCompetidores):
    ganadores = []
    for j in range(cantidadIndividuos):
        competidores = []
        fitness_competidores = []
        for i in range(cantidadCompetidores):
            c=random.randint(0,len(poblacion)-1)
            competidores.append(poblacion[c])
            fitness_competidores.append(fitnessValores[c])
        ganador = competidores[fitness_competidores.index(max(fitness_competidores))]
        ganadores.append(ganador)
    return ganadores
```

Ejecuta el ciclo evolutivo del algoritmo genético con elitismo, es decir, conservando a los mejores individuos de cada generación. En cada iteración se hace selección, cruzamiento, mutación y se agregan los elitistas a la nueva población. Además, al final se almacenan los valores de las métricas medidas de cada iteración.

```
# Elitismo
def ciclos_con_elitismo(ciclos, prob_crossover, prob_mutacion,cantidadIndividuos, cantidadGenes, metodo_seleccion,
cantidadElitismo, cantidadCompetidores=None):
    maximos=[]
    minimos=[]
    promedios=[]
    mejores=[]
    pob = generarPoblacion(cantidadIndividuos,cantidadGenes)
    fit = calculadorFitness(pob)
    rta = calculadorEstadisticos(pob)
    for j in range (ciclos):
        elitistas = []
        fitness_individuos = list(zip(fit, pob))
        fitness_individuos.sort(key=lambda x: x[0], reverse=True)
        for i in range(cantidadElitismo):
            elitistas.append(fitness_individuos[i][1])
        pob_sin_elitistas = [ind for ind in pob if ind not in elitistas]
        if len(pob_sin_elitistas) < cantidadIndividuos - cantidadElitismo:
            pob_sin_elitistas = pob
        fit_sin_elitistas = calculadorFitness(pob_sin_elitistas)
        if metodo_seleccion == 'r':
            pob = seleccionRuleta(pob_sin_elitistas, fit_sin_elitistas, cantidadIndividuos-cantidadElitismo)
        else:
            pob = seleccionTorneo(pob_sin_elitistas, fit_sin_elitistas, cantidadIndividuos-cantidadElitismo, cantidadCompetidores)
        for i in range (0,len(pob),2):
            padre = pob[i]
            if i+1 < len(pob):  # Verificar que existe la madre
                madre = pob[i+1]
                if random.random() < prob_crossover :
                    hijo1, hijo2 = crossover1Punto(padre,madre)
                    pob[i], pob[i+1] = hijo1, hijo2
                if random.random() < prob_mutacion:
                    pob[i] = mutacionInvertida(pob[i])
                if random.random() < prob_mutacion:
                    pob[i+1] = mutacionInvertida(pob[i+1])
            else:
                if random.random() < prob_mutacion:
                    pob[i] = mutacionInvertida(pob[i])
        pob = elitistas + pob
        fit = calculadorFitness(pob)
        rta = calculadorEstadisticos(pob)
        maximos.append(rta[0])
        minimos.append(rta[1])
        promedios.append(rta[2])
        mejores.append(rta[3])
    return maximos, minimos, promedios, mejores
```

Ejecuta el ciclo evolutivo sin conservar explícitamente los mejores individuos. En cada generación se hace selección, cruzamiento y mutación.

```
# Sin elitismo
def ciclos_sin_elitismo(ciclos, prob_crossover, prob_mutacion, cantidadIndividuos, cant_genes, metodo_seleccion,
cantidadCompetidores=None):
    maximos=[]
    minimos=[]
    promedios=[]
    mejores=[]
    pob = generarPoblacion(cantidadIndividuos, cant_genes)
    for j in range(ciclos):
        fit = calculadorFitness(pob)
        rta = calculadorEstadisticos(pob)
        maximos.append(rta[0])
        minimos.append(rta[1])
        promedios.append(rta[2])
        mejores.append(rta[3])
        if metodo_seleccion == 'r':
            pob = seleccionRuleta(pob, fit, cantidadIndividuos)
        else:
            pob = seleccionTorneo(pob, fit, cantidadIndividuos, cantidadCompetidores)
        for i in range(0, len(pob), 2):
            padre = pob[i]
            madre = pob[i+1]
            if random.random() < prob_crossover:
                hijo1, hijo2 = crossover1Punto(padre, madre)
                pob[i], pob[i+1] = hijo1, hijo2
            if random.random() < prob_mutacion:
                pob[i] = mutacionInvertida(pob[i])
            if random.random() < prob_mutacion:
                pob[i+1] = mutacionInvertida(pob[i+1])
    return maximos, minimos, promedios, mejores
```

La función formatear_hoja_excel aplica formato automático a una hoja de cálculo de Excel ajustando el ancho de todas las columnas según el contenido más largo de cada una y estableciendo la primera fila en formato negrita para resaltar los encabezados. Esto mejora la presentación de los datos exportados, eliminando la necesidad de ajustar manualmente el formato después de generar el archivo Excel.

```
def formatear_hoja_excel(hoja_trabajo):
    from openpyxl.styles import Font
    for columna in hoja_trabajo.columns:
        longitud_maxima = 0
        letra_columna = columna[0].column_letter
        for celda in columna:
            try:
                if len(str(celda.value)) > longitud_maxima:
                    longitud_maxima = len(str(celda.value))
            except:
                pass
        ancho_ajustado = min(longitud_maxima + 2, 50)
        hoja_trabajo.column_dimensions[letra_columna].width = ancho_ajustado
    for celda in hoja_trabajo[1]:
        celda.font = Font(bold=True)
```

Genera un archivo Excel con los datos de cada generación: máximos, mínimos, promedio de aptitud y el mejor cromosoma. Se utiliza para registrar los resultados y poder analizarlos o compararlos luego.

Crea un gráfico que contiene las curvas de los máximos, los mínimos y los promedios de aptitud por ciclo para visualizar la evolución del rendimiento del algoritmo a lo largo de las generaciones.

```
def generar_grafico(maximos, minimos, promedios, mejores, titulo, ciclo):
    x = list(range(len(maximos)))
    fig, ax = plt.subplots(figsize=(10, 6))
    ax.plot(x, maximos, label = 'Máximos',  marker='o', linestyle='-', color='b', linewidth=1, markersize=2)
    ax.plot(x, minimos, label = 'Mínimos', marker='o', linestyle='-', color='g', linewidth=1, markersize=2)
    ax.plot(x, promedios, label = 'Promedios', marker='o', linestyle='-', color='r', linewidth=1, markersize=2)
    ax.set_title('Máximos, Mínimos y Promedios')
    ax.set_xlabel('CORRIDA',fontsize=12)
    ax.set_ylabel('APTITUD',fontsize=12)
    ax.set_ylim(0, 1.2)
    ax.set_xlim(0, ciclo + 2)
    ax.grid(True)
    ax.legend(fontsize = 10)
    fig.suptitle(titulo, fontsize=15)
    plt.tight_layout(rect = [0, 0, 1, 0.95])
    plt.savefig(titulo.replace(" ", "_") + '.png')
    plt.show()
```

Por último, el Programa Principal. En este bloque define los parámetros generales del algoritmo genético, como la probabilidad de cruzamiento (probCrossover), de mutación (probMutacion), la cantidad de individuos por generación y la cantidad de genes por cromosoma. También toma los argumentos de entrada desde la consola, que indican la cantidad de ciclos a ejecutar, el tipo de selección (r para ruleta o t para torneo) y si se aplica elitismo (1 sí, 0 no).

Luego, según los argumentos recibidos, elige si ejecutar el ciclo con o sin elitismo, usando las funciones ciclos_con_elitismo o ciclos_sin_elitismo. Al finalizar, genera un gráfico con la evolución de los valores máximos, mínimos y promedios de aptitud, y exporta una tabla Excel con los resultados por ciclo para su análisis.

En resumen, este bloque es el punto de entrada del programa, controla el flujo principal del algoritmo genético y gestiona la visualización y guardado de resultados. Se puede observar en la siguiente página la sección de código del mismo.

```
# PROGRAMA PRINCIPAL
probCrossover = 0.75
probMutacion = 0.05
cantidadIndividuos = 10
cantidadElitismo = 2
cantidadCompetidores = int(cantidadIndividuos * 0.4)
cantidadGenes = 30
maximosPorCiclo = []
minimosPorCiclo = []
promediosPorCiclo = []
if len(sys.argv) != 7 or sys.argv[1] != "-c" or sys.argv[3] != "-s" or sys.argv[5] != "-e":
    print("Uso: python TP1_AG_G2.py -c <ciclos> -s <seleccion: r-ruleta t-torneo> -e <elitismo: 1-si 0-no>")
    sys.exit(1)
if int(sys.argv[2]) < 0 or (int(sys.argv[6]) != 0 and int(sys.argv[6]) != 1) or (sys.argv[4] != "r" and sys.argv[4] != "t"):
    print("Error: python TP1_AG_G2.py -c <ciclos> -s <seleccion: r-ruleta t-torneo> -e <elitismo: 1-si 0-no>")
    sys.exit(1)
ciclosPrograma = int(sys.argv[2])
if int(sys.argv[6]) == 1:
    maximosPorCiclo, minimosPorCiclo, promediosPorCiclo, mejores = ciclos_con_elitismo(ciclosPrograma,probCrossover, probMutacion, cantidadIndividuos,
cantidadGenes, sys.argv[4], cantidadElitismo=cantidadElitismo, cantidadCompetidores=cantidadCompetidores)
    if sys.argv[4] == 'r':
        titulo = 'Selección RULETA ELITISTA - '+ str(ciclosPrograma) + ' ciclos'
    else:
        titulo = 'Selección TORNEO ELITISTA - '+ str(ciclosPrograma) + ' ciclos'
    generar_grafico(maximosPorCiclo, minimosPorCiclo, promediosPorCiclo, mejores, titulo, ciclosPrograma)
    crear_tabla(maximosPorCiclo, minimosPorCiclo, promediosPorCiclo, mejores, sys.argv[4], int(sys.argv[6]))
else:
    maximosPorCiclo, minimosPorCiclo, promediosPorCiclo, mejores = ciclos_sin_elitismo(ciclosPrograma,probCrossover, probMutacion, cantidadIndividuos,
cantidadGenes, sys.argv[4], cantidadCompetidores=cantidadCompetidores)
    if sys.argv[4] == 'r':
        titulo = 'Selección RULETA - '+ str(ciclosPrograma) + ' ciclos'
    else:
        titulo = 'Selección TORNEO - '+ str(ciclosPrograma) + ' ciclos'
    generar_grafico(maximosPorCiclo, minimosPorCiclo, promediosPorCiclo, mejores, titulo, ciclosPrograma)
    crear_tabla(maximosPorCiclo, minimosPorCiclo, promediosPorCiclo, mejores, sys.argv[4], int(sys.argv[6]))
```

## Salidas por pantalla

Los datos obtenidos en cada generación fueron almacenados en archivos Excel. Como algunas de las corridas se realizaron para gran cantidad de generaciones, decidimos subir estos archivos a una carpeta de drive y compartir el link. Esto debido a que examinar directamente esa cantidad de valores numéricos podría ser tedioso y no le aportaría tanto a la conclusión, así como lo hacen los gráficos de la siguiente sección.

Link:

https://drive.google.com/drive/folders/1Th12fWT9TuVWHyZnt1ePVbe9SKPeT2lQ?usp=sharing

## Gráficas

### Sin Elitismo

#### Ruleta

Para 20 corridas:

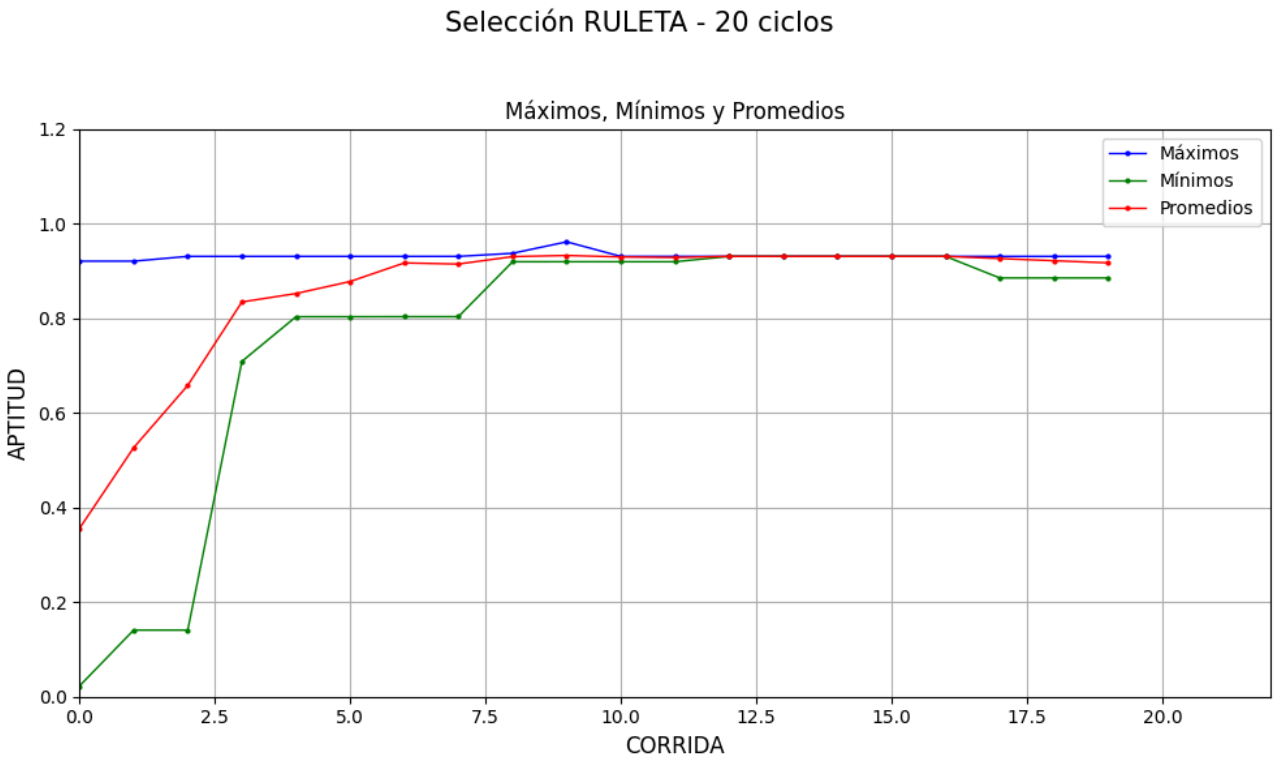


Como se puede observar en la imagen, es difícil que varíe la curva de los máximos a no ser que sufran una mutación, cosa que no sucede en este caso, ya que al tener más probabilidades de salir en la ruleta, se mantienen aunque pasen por el crossover. Esto se da debido a que la parte de mayor peso del número binario es la que indica que tan grande el número es, y la parte de menor peso no modifica tanto el número.

En la curva de los mínimos se puede observar que es mayoritariamente creciente, los números más altos tienen mayor probabilidad de ser los que pasen por el crossover y generen la nueva población, es por ello que los valores mínimos son cada vez más altos a no ser que salga sorteado un valor con probabilidad baja o que algún cromosoma sufra una mutación en algún gen que represente un bit de peso.

Por último, en la curva de promedios se observa una tendencia a seguir la forma de la gráfica de mínimos, ya que la de máximos no se mueve tanto y que como los mínimos son cada vez más grandes implica que los valores de la población en general son más grandes.

Para 100 corridas:

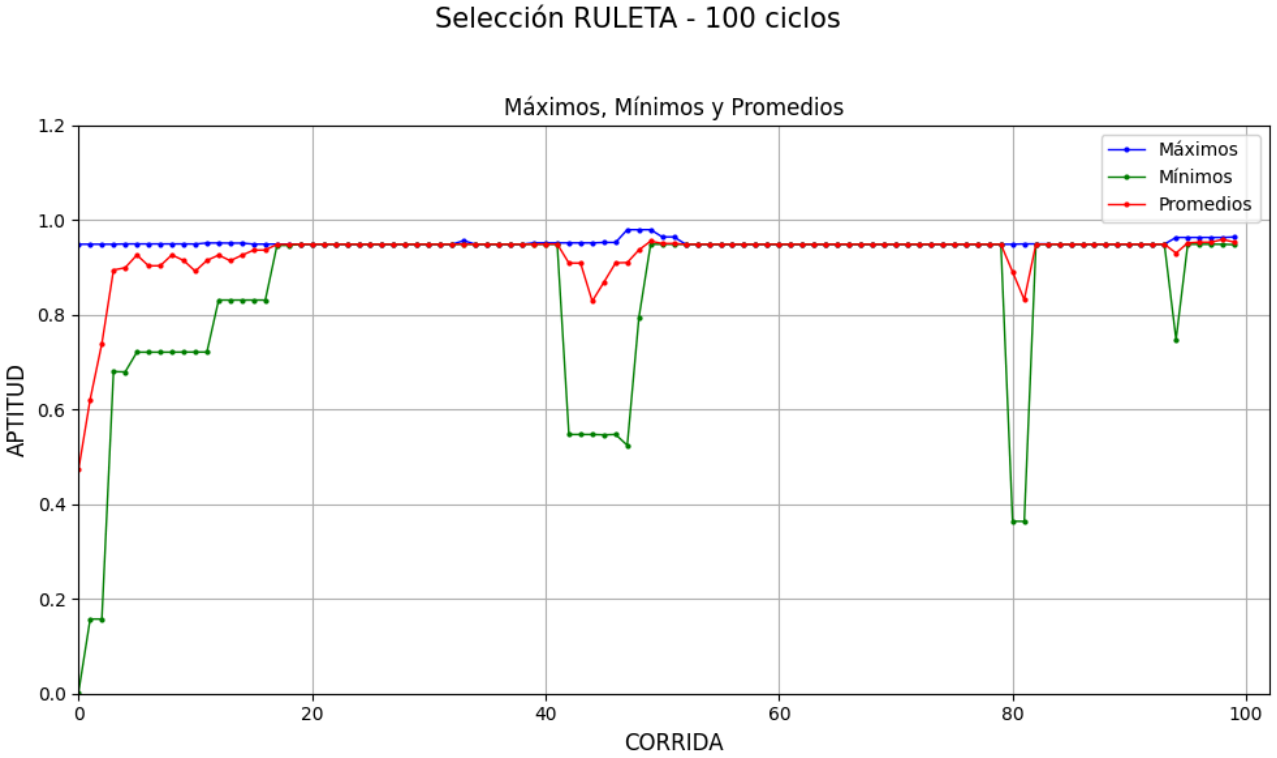


A diferencia del gráfico anterior, en este caso se puede observar que la curva de los máximos llega a niveles elevados de aptitud ya desde el primer ciclo. Esta situación se da en forma constante hasta aproximadamente los 50 ciclos. Luego vuelve a tomar un valor similar al inicial que mantendrá hasta el final

Los mínimos y los promedios tienden a crecer, estabilizándose pasando la corrida número veinte, pero luego se observan picos hacia abajo en alguna que otra iteración aislada, lo que lleva a pensar una vez más en mutaciones que generaron valores mínimos que no superan el siguiente sorteo.

Para 200 corridas:

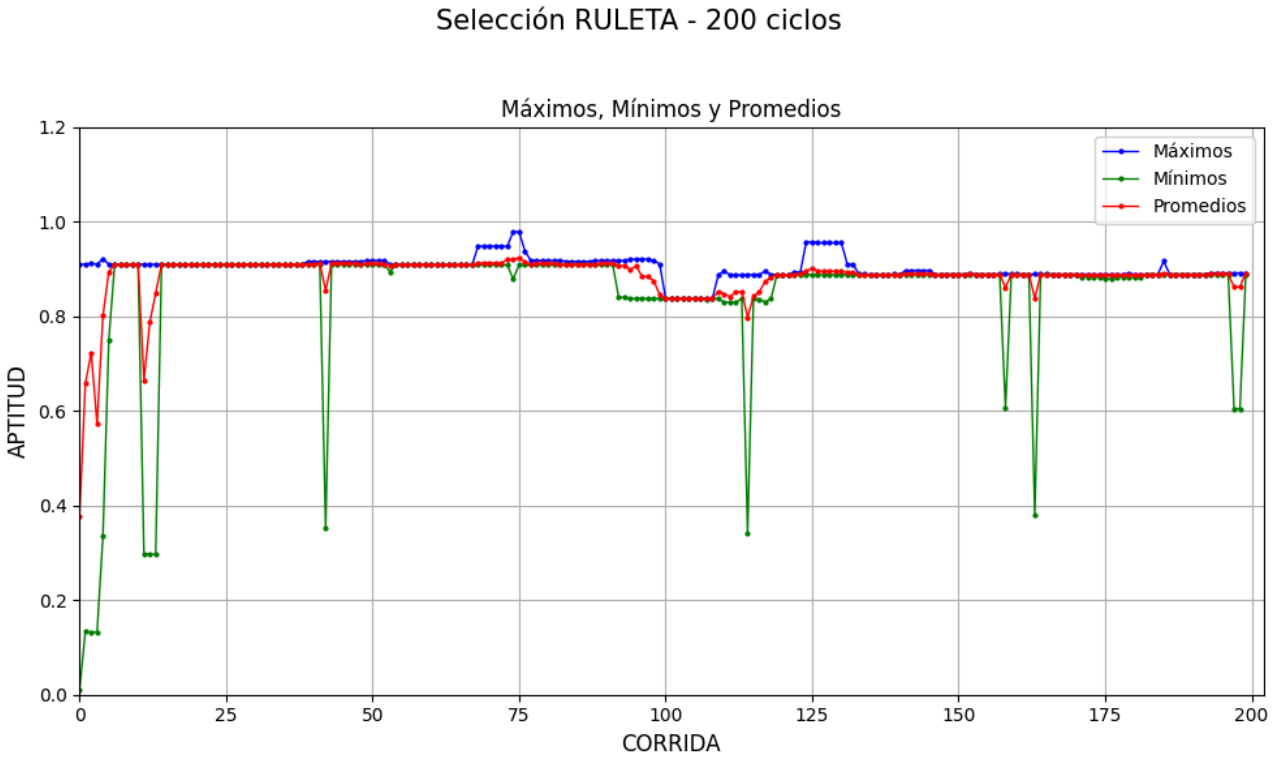


Al igual que en la gráfica anterior, se pueden observar picos en las curvas, pero al tratarse esta vez de una mayor cantidad de generaciones, hay también más oportunidades de que estas variaciones ocurran a lo largo de la simulación. A diferencia del caso anterior, aquí se observan mutaciones que no solo introducen variabilidad negativa, sino que también generan mejoras en la población, como se aprecia en al menos dos ocasiones en la curva de máximos. La mutación ocurrida aproximadamente en la generación 60 produjo un leve aumento momentáneo en el máximo, aunque su efecto desapareció apenas varias iteraciones después. En cambio, las mutaciones surgidas entre las generaciones 110 y 125 logró mantenerse por unas corridas, evidenciando que el algoritmo es capaz de encontrar una solución óptima, pero sin garantía de preservarla. La presencia de oscilaciones y falta de estabilidad refuerzan la idea de que, sin elitismo, las mejores soluciones pueden perderse fácilmente por efectos del azar (mutaciones o decisiones de selección desfavorables).

La curva de mínimos es donde se manifiesta con mayor claridad esta inestabilidad. Aunque en general los valores tienden a mejorar con el tiempo, aparecen múltiples descensos bruscos y profundos en distintas etapas del proceso, incluso hacia el final. Esto sugiere que, sin un mecanismo de conservación como el elitismo, los individuos de baja aptitud pueden seguir ingresando a la población, ya sea por mutación o recombinación aleatoria, y no hay forma de impedir su permanencia temporal. A diferencia de los máximos, esta curva no muestra una estabilización clara.

En cuanto a la aptitud promedio, se observa una mejora sostenida a lo largo de las generaciones, con un salto notable que coincide con el ascenso en la curva de máximos. A partir de ese punto, el promedio se mantiene en valores elevados, aunque con caídas esporádicas que reflejan la presencia ocasional de individuos poco aptos. Estas oscilaciones coinciden en general con los descensos en la curva de mínimos, y muestran cómo incluso una pequeña porción de la población puede seguir afectando el rendimiento general cuando no se protege explícitamente la calidad de las soluciones ya obtenidas.

### Torneo

Para 20 corridas:

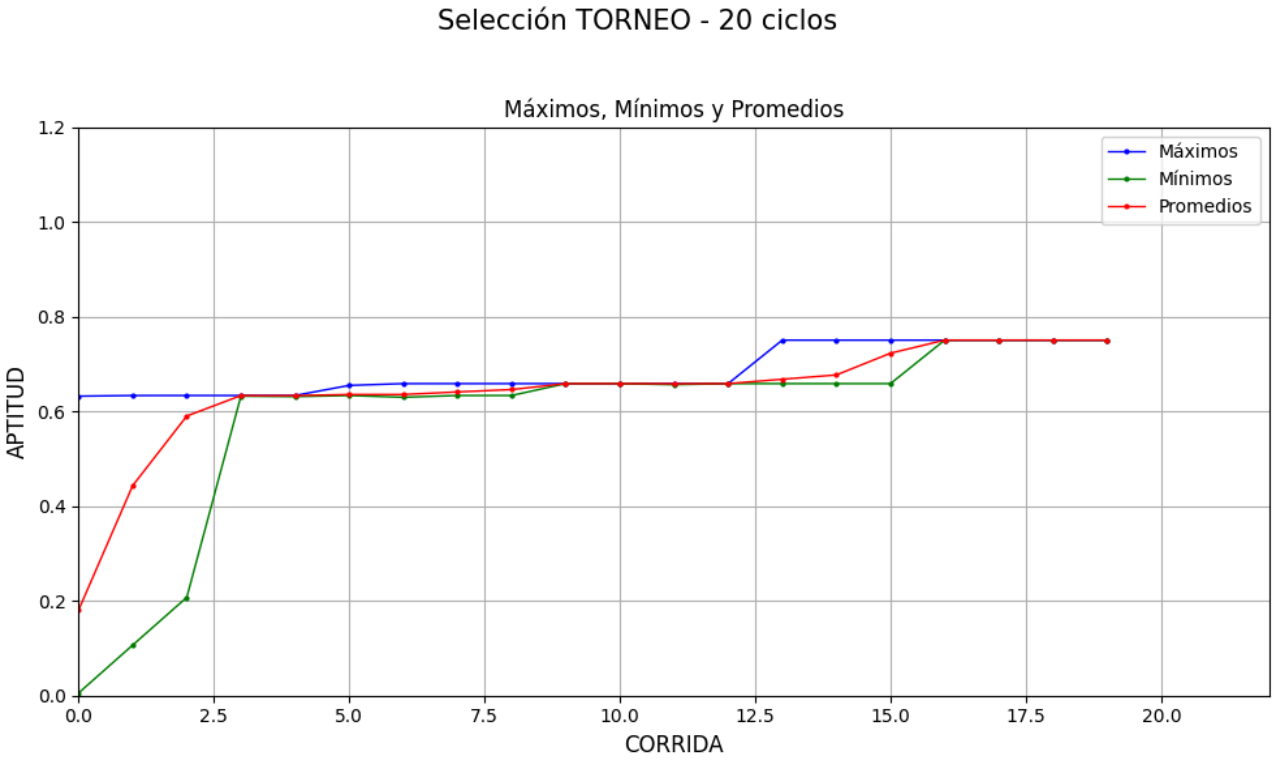


La aptitud máxima se eleva durante las primeras generaciones, para luego tender a mantenerse constante hasta ¾ de las corridas, donde se produce un leve aumento . Esto indica que el algoritmo logra mejorar la mejor solución pero de forma muy lenta.

La aptitud mínima comienza cerca del cero y sube rápidamente en las primeras tres corridas, estabilizandose luego. Esto sugiere una mejora inicial del conjunto poblacional, para luego elevarse en la decimoquinta corrida.

El promedio de aptitud aumenta rápidamente al principio y luego se estabiliza en la tercer corrida. Esto es coherente con el comportamiento de los mínimos y refleja que la población general mejora al principio, pero no logra avanzar mucho más allá.

Para 100 corridas:

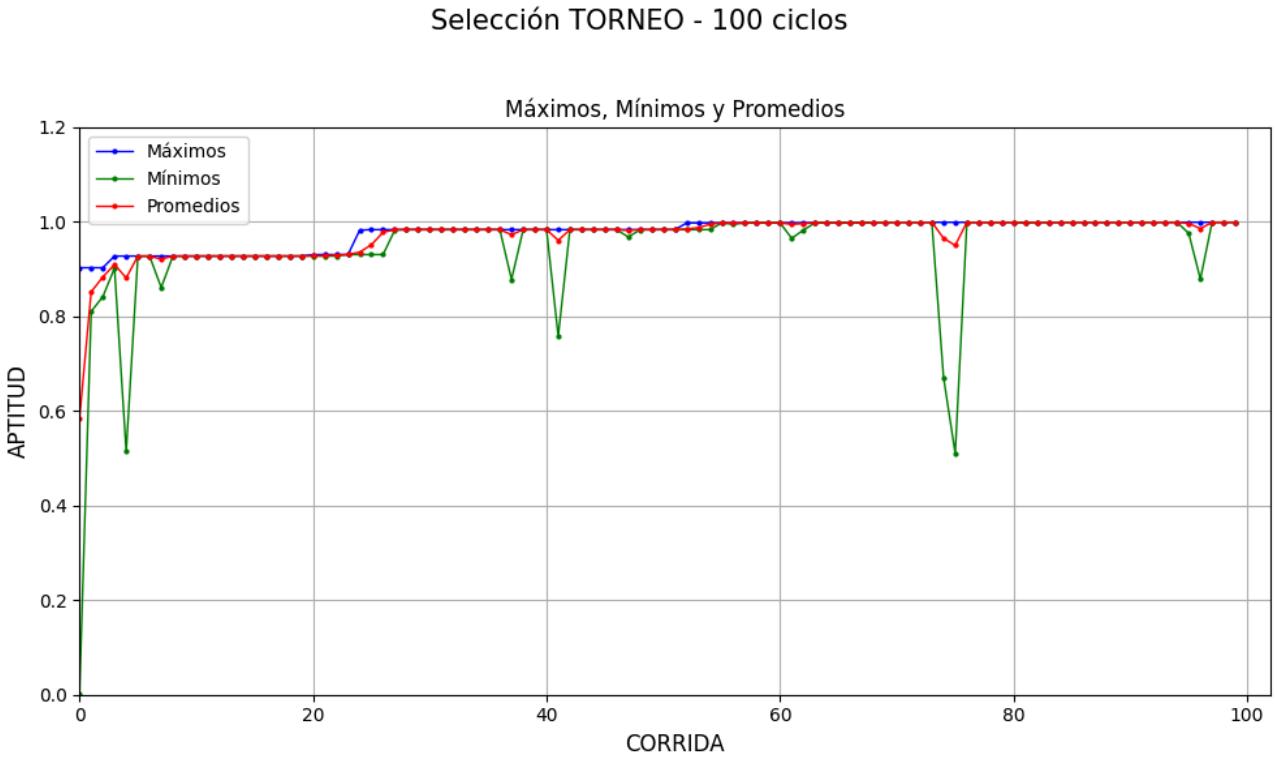


La aptitud máxima comienza cerca de 0.91 a dar saltos leves para terminar manteniéndose constante de la generación 25, manteniéndose en ese valor. Esto indica que el algoritmo eventualmente encuentra una solución óptima o muy cercana. La mejora no es continua, sino que ocurre en un salto puntual.

La curva de los mínimos es más inestable, habiendo varias caídas abruptas pero en una cantidad no tan elevada, siendo la más importante la de la corrida 75 aproximadamente.

La media muestra una tendencia general a la de la curva de las aptitudes máximas, aunque con oscilaciones. Debido a la mutación de la curva de aptitudes mínimas en la corrida 75 ocurre un leve descenso del promedio.

Para 200 corridas:

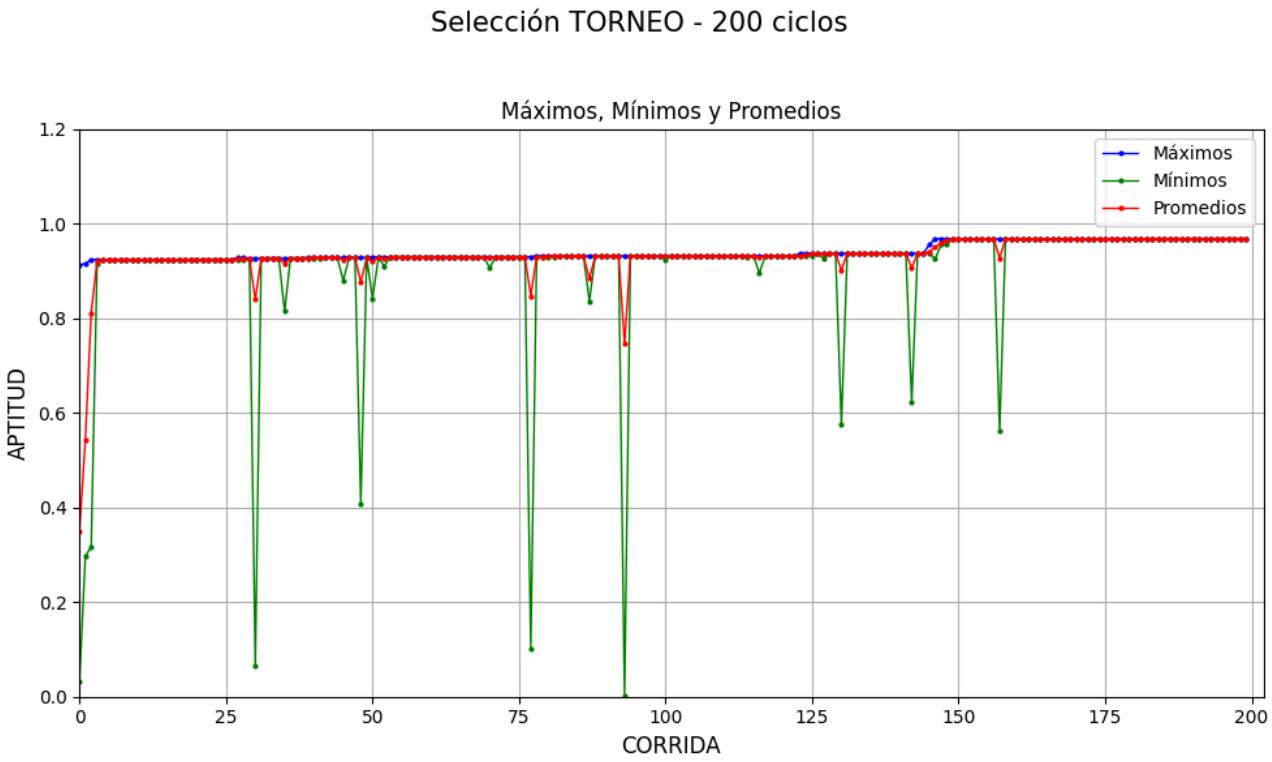


A diferencia del gráfico anterior, en éste se puede observar como la curva de máximos se mantiene constante, elevándose levemente. Mientras que la curva de mínimos muestra que se originaron una gran cantidad de mutaciones debido a la gran cantidad de caídas abruptas, llegando incluso una vez a la aptitud mínima.

La curva de las aptitudes mínimas origina en la curva de promedios leves caídas debido a las mutaciones que la afectaron.

Podemos así concluir de que a mayor número de generaciones es más probable que sucedan mutaciones (aún más con el número de probabilidad con el que se trabajó), viéndose reflejadas como picos en las gráficas. Aún así no son de mayor inconveniente porque no sobreviven más de una generación.

### Con elitismo

Para ambos casos se decidió realizar una corrida de cien generaciones.

## Ruleta

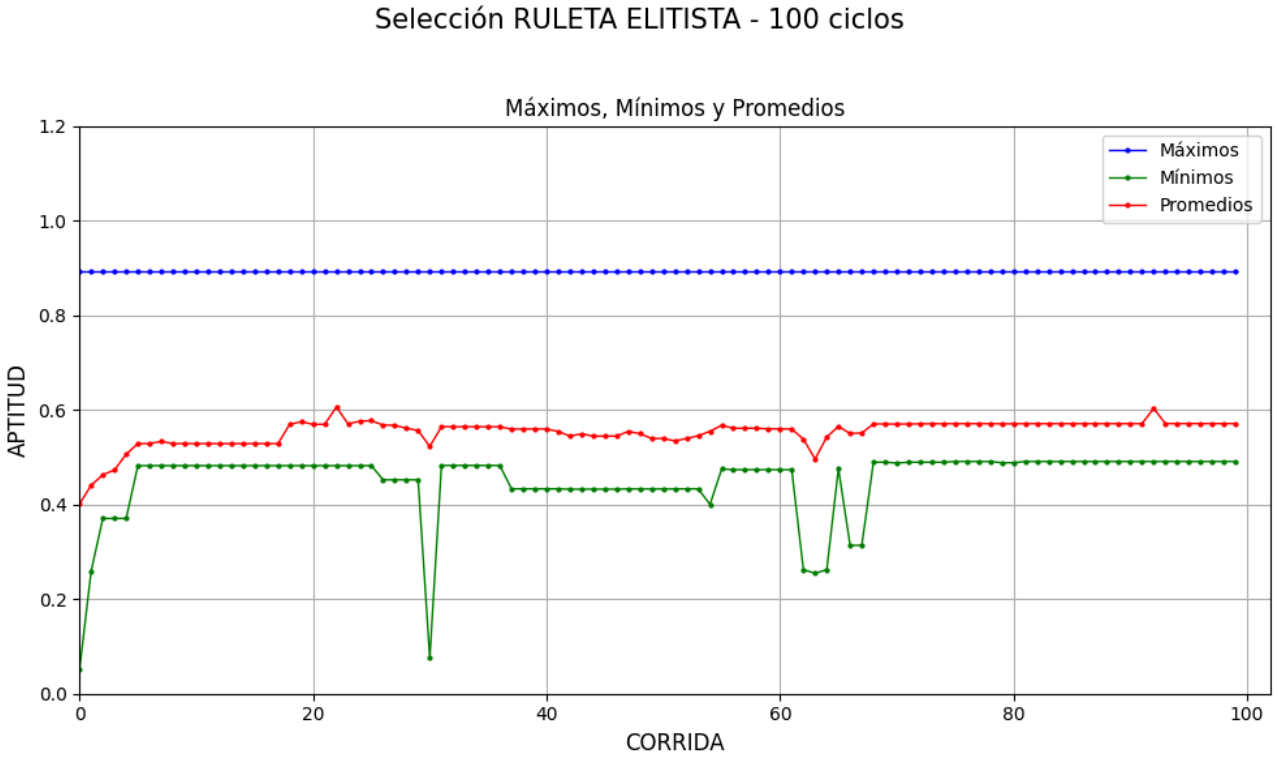


En esta simulación se observa en la curva de aptitudes máximas un comportamiento notablemente más estable y eficiente en comparación con las ejecuciones sin elitismo. En este caso, la curva de máximos muestra un claro valor constante, 0,9, a lo largo de las 100 generaciones. Esto es una señal de que el elitismo asegura su preservación, evitando que el mejor individuo se pierda por mutación o azar. Además, en este caso en particular podemos concluir que al tener una valor de aptitud elevado en las primeras corridas, el valor del mismo se mantendrá pero convergiendo en probabilidad al óptimo en el caso de que el número de corridas o la probabilidad de mutación sean mayores.

La curva de mínimos muestra una tendencia general ascendente durante las primeras corridas, aunque luego presenta algunos pequeños descensos puntuales. Estos picos pueden atribuirse a mutaciones que generan individuos de baja aptitud que, al no ser seleccionados ni protegidos por elitismo, no perduran más de una o dos generaciones. Aun así, el elitismo protege la calidad global, lo que se refleja en una curva que rápidamente vuelve a subir.

El gráfico del promedio sigue un camino similar al de los mínimos, mostrando leves caídas cuando en la curva de mínimos se originan caídas abruptas debido a las mutaciones. Además también mantiene una constancia gracias a la curva de máximos, aunque con niveles de aptitud menores debido a la curva de mínimos. Esto refuerza la idea de que el elitismo contribuye a mejorar la población completa, no solo a conservar los mejores.

### Torneo

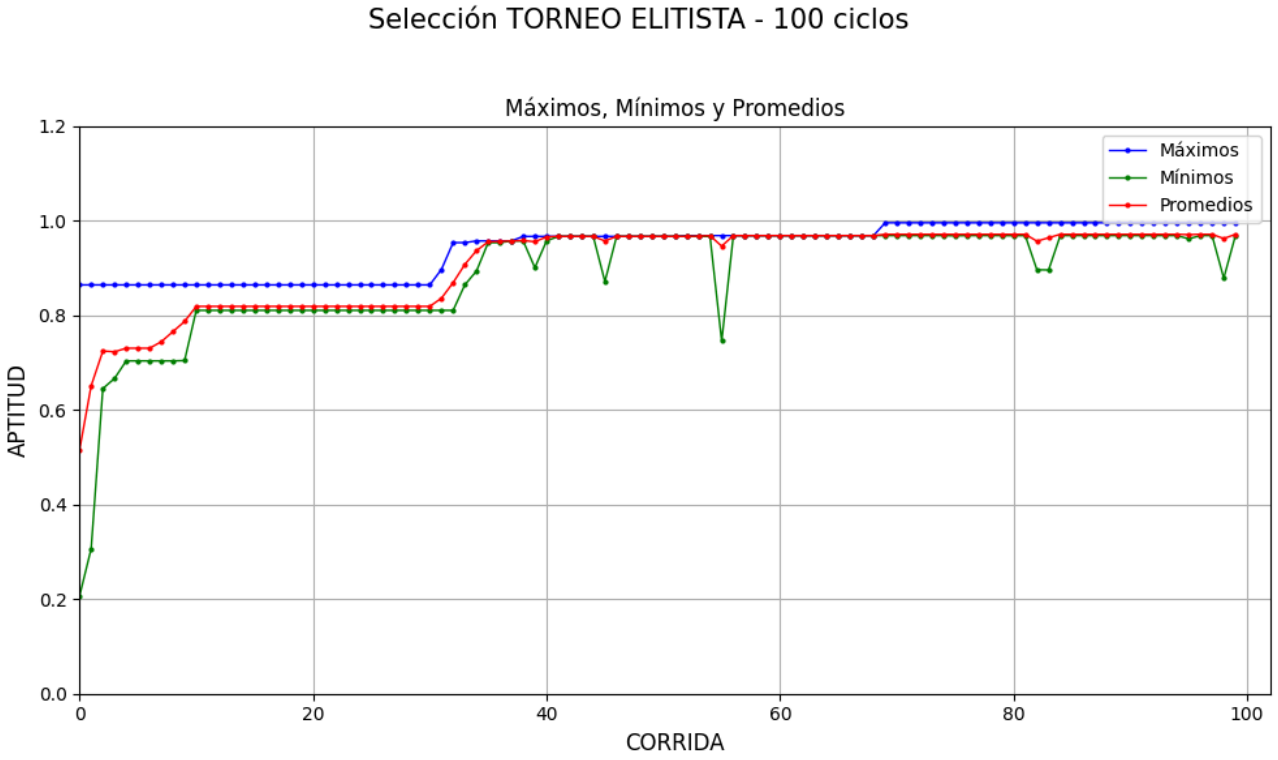


Este segundo gráfico, correspondiente al método de torneo con elitismo, también muestra una evolución clara hacia la convergencia óptima. La curva de máximos comienza en un valor intermedio, ascendiendo en muy pocas ocasiones, estabilizándose en aproximadamente 0.99 (muy cercano al óptimo). Al igual que en el caso anterior, una vez alcanzado el valor máximo, el elitismo evita su pérdida, consolidando una población cada vez más apta.

La curva de mínimos, si bien algo más irregular que en el caso de ruleta, también sigue una tendencia ascendente. Se observan algunos picos bruscos y breves hacia abajo, señal de la aparición esporádica de mutaciones o combinaciones que producen malos individuos. Sin embargo, al contar con elitismo, estos individuos no afectan la permanencia de los mejores, lo que evita que estos valores bajos se perpetúen.

La curva del promedio crece con una pendiente muy leve y constante, lo que indica una mejora colectiva sostenida de la población. Las oscilaciones son suaves, lo que refleja la efectividad del torneo (en este caso con elitismo) para preservar buenas soluciones y explorar nuevas al mismo tiempo.

## Conclusiones

A lo largo del desarrollo del trabajo práctico, se observaron diferencias marcadas en el comportamiento de los algoritmos genéticos según el método de selección utilizado y la presencia o ausencia de elitismo. La selección por ruleta, si bien es sencilla de

implementar y basa sus decisiones en una lógica probabilística proporcional al fitness, mostró una fuerte dependencia de las mutaciones para producir mejoras significativas. En varias simulaciones, los valores máximos se mantuvieron estancados hasta que una mutación afortunada introdujo una solución de mayor calidad, lo que evidencia una presión selectiva débil y una convergencia más lenta hacia el óptimo.

En contraste, la selección por torneo arrojó resultados más dinámicos, ya que favorece de manera directa a los individuos con mayor fitness dentro de subconjuntos aleatorios de la población. Esto permitió una mejora más rápida de los valores máximos, aunque también introdujo una mayor variabilidad en los mínimos. La falta de elitismo en ambos métodos permitió que individuos de alta calidad se pierdan ocasionalmente.

La lentitud de convergencia del método de ruleta se explica porque incluso los peores individuos conservan una probabilidad no nula de ser seleccionados, mientras que los mejores pueden quedar fuera del proceso de cruce. Por su parte, el método de torneo también presenta vulnerabilidades, si se enfrentan dos individuos de baja calidad en una misma competencia, uno de ellos avanzará, y si los mejores compiten entre sí, sólo uno continuará. Esto puede derivar en un deterioro de la calidad de la población. En este contexto, la incorporación de elitismo se reveló como un factor clave para estabilizar la evolución del algoritmo, ya que garantiza la conservación de las mejores soluciones y favorece tanto la convergencia como la mejora general de la población.

En resumen, mientras que la ruleta tiende a avanzar de forma más lenta y dependiente del azar, el torneo permite mejoras más rápidas pero con menor estabilidad. El elitismo actúa como un mecanismo de protección que mitiga las debilidades de ambos métodos, permitiendo una evolución más sólida y sostenida hacia la solución óptima.